

Temă: Memory, Caching & Intent Classifier

Optimizează Agentul

Ce trebuie făcut:

1

Conversation Memory (L8)

- Adaugă ConversationMemory la Agent
- Integrează în nodul LangGraph — context persistent între request-uri
- Persistă memoria în PostgreSQL pentru long-term storage

2

Prompt Caching (L8)

- Activează prompt caching Anthropic (cache_control: ephemeral)
- Pune system prompt-ul și contextul fix în cache
- Măsoară tokens economisiți și reducerea de latență

3

Intent Classifier cu scikit-learn (L7)

- Antrenează un text classifier: TF-IDF + LogisticRegression
- Date de antrenare: query + label (search / extract / summarize)
- Compară într-un script latentă, costul și accuracy-ul predicție între llm și clasicator.